

BEVFormer 模型调试实战复盘

从「heatmap 全紫、检测无框」到「9 张图全部命中 GT」 · 2026-09-29

一、今天做了什么

模型训练“看起来在跑”但可视化全错：heatmap 全紫、检测图无框。今天用一天时间挖出了 6 层嵌套的根因，逐层修复后重训 30 epoch，cls loss 从 11.67 降到 0.27，9 张可视化图全部达标。

指标	修复前	修复后
cls loss	卡死在 0.765（不可学任务的理论最优值）	**0.27**，持续下降
heatmap	全紫一片，无任何亮斑	亮斑精确落在 GT 物体位置
检测图	无框或一堆乱框	一框对一物，分数 0.44 ~ 0.71
框数量	14 / 19 / 12 / 15（大量重复）	4 / 4 / 5 / 4（恰好等于物体数）

核心认知：模型不收敛 ≠ 调参问题，先怀疑“任务本身不可学”。当 loss 卡在一个“奇怪的稳定值”，它往往不是噪声，而是模型对当前任务的理论最优解——这是破案的第一条线索。

二、数值破案：两条铁证

2.1 铁证一：cls = 0.765 是“不可学任务”的理论最优值

训练日志里 cls loss 长期卡在 0.765 不动。用 Focal Loss 的数学性质反推：

- 数据集正负样本比约 1:40，Focal Loss 下“全图输出同一个低概率背景值”就能把 loss 压到一个局部最优；
- 反推该值对应每个网格的 sigmoid 输出 ≈ 0.04 （全图统一输出背景概率 4%）；
- 模型“看穿”了图像里没有可用于定位物体的信息，干脆输出常数——这正是“图像与标签无几何对应”时的理论最优解。

2.2 铁证二：reg $\equiv 1.0$ 是“均匀分布”的指纹

回归 loss 恒等于 1.0，一点不降。L1 Loss 对均匀分布预测的期望值正好是 1.0——说明模型输出的中心偏移量完全是“瞎猜”。分类和回归同时退化为常数输出，说明病灶不在检测头，而在上游特征根本没传过来。

学习点：训练日志不是“等它降就完事”的进度条，而是模型的体检报告。看到反常的稳定值，先算一算它的解析含义。

三、六层根因逐层拆解

按挖掘顺序（也是依赖顺序）整理。每层独立看都是“小 bug”，叠在一起就是“完全学不动”。

Bug 1 • 数据不可学（根因中的根因）

现象：模型怎么训都收敛到常数输出。

根因：原 dataset.py 中图像和 GT 热图是两次独立随机生成 —— 图像上的色块和 GT 框的位置毫无几何关系，等于让模型从噪声里预测另一份噪声。

修复：新增 _generate_scene_objects()，每帧先生成 3~8 个物体（类别/位置/尺寸），**图像和 GT 共用同一份物体数据源**；图像用与 SCA 完全一致的投影代码 project_bev_to_image 把物体画成色块（近大远小、按类别着色）。

教训：**投影一致性必须贯穿“数据生成 → SCA 采样 → 可视化”全链路**，任何一处用了不同的几何假设，模型学的就是错误对应。

Bug 2 • meshgrid 顺序转置（坐标约定不一致）

现象：即使数据对了，定位信号仍然错位。

根因：SCA 与位置编码用 meshgrid(z, y, x) (y-major 展平)，检测头把 BEV 特征 view(B,H,W,C) (x-major 展平)。同一个 query 在两边对应物理空间中不同的点，位置编码等于全部加错。

修复：全链路统一为 x-major: torch.meshgrid(xs, ys, zs, indexing="ij")，并用 6 个抽样索引做数值验证。

教训：**展平顺序是 BEV 系统最隐蔽的 bug 源，必须全工程统一并在关键模块间做数值对齐测试。**

Bug 3 • grid_sample 归一化错误（97% 采样点越界）

现象：SCA 采样到的图像特征几乎全 0。

根因：把原图像素坐标除以了特征图宽度(8)而不是原图宽高(256)，**“归一化坐标”范围成了 [-1, 63]**，而 F.grid_sample 只认 [-1,1] —— 97% 的采样点落在界外，采回来全是 0。

修复：grid_u = 2 * pix_x / img_w - 1，并把 img_h / img_w 显式透传到 SCA 层。实测有效采样率从 3.1% 恢复到 100%。

教训：**grid_sample 的坐标是归一化到 [-1,1] 的原图坐标，除数永远是原图尺寸，不是特征图尺寸。**

Bug 4 • TSA 无历史帧时的全局自平均

现象：第一帧（没有任何历史 BEV）信号被抹平。

根因：简化版 TSA 用全连接 self-attention 代替原版 deformable attention。无历史帧时 K/V 退化为当前帧自身，2500 个 query 互相平均，把 SCA 刚建立的局部定位信号稀释成均匀背景。

修复：无历史帧时恒等返回；有历史帧时 K/V 只取历史帧（不拼当前帧）。

教训：用标准 attention 替代 deformable attention 时，要清楚替代品改变了“每个 query 看哪里”的归纳偏置——原版 query 只看自己空间对应的位置，全连接版会全局平均。

Bug 5 • Post-LN 破坏加性信号（最深层、最反直觉）

现象：消融实验：裸 SCA 输出前景 0.178 / 背景 0.018（信号清晰），只加一层 LayerNorm 就崩到 0.052 / 0.040。

根因：Post-LN（残差相加后再归一化）对每个 token 重新缩放。本模型是“强随机 query + 小幅加性物体信号 δ ”的设计，Post-LN 把 δ 连同残差一起归一化掉，破坏了“物体位置数值偏大”的线性可分性。

修复：改为 Pre-LN：归一化只作用于注意力/FFN 的输入分支，残差主路径保持原始尺度。

教训：Pre-LN vs Post-LN 不是风格问题，是“残差主路径保不保真”的问题。现代 DETR 系（含 BEVFormer 原版）全部用 Pre-LN 变体不是偶然。

Bug 6 • 两个辅助病灶

CNN 看不见色块：原背景 ± 0.2 强噪声下，色块下采样后能量比仅 1.08。修复：背景改平缓灰调 (± 0.03)、色块高对比着色加描边。人眼一眼看不出的目标，CNN 更看不出。

采样冷启动死锁：所有 offset 初始为 0，9 个采样点重叠在一个像素上，小目标永远采不到、offset 永远学不动。修复：bias 初始化为 3×3 散开网格 ($\pm 22\text{px}$)。初始化要保证“第一步就有信息流”。

四、验证方法论：不猜，用实验说话

步骤	手段	通过标准	实测结果
1	数据冒烟测试	投影颜色命中 GT 位置	16/17 命中
2	展平顺序数值验证	SCA/head 索引逐点对齐	6/6 索引全对
3	采样有效性探针	归一化坐标在 $[-1, 1]$	3.1% $\rightarrow$ 100%
4	过拟合实验 (2 序列 $\times$ 150 步)	前景/背景概率显著分离	0.149 vs 0.0118 (12.6 倍)
5	组件消融 (裸 SCA $\rightarrow$ +LN $\rightarrow$ +FFN)	定位“哪一层加进去崩的”	+一层 LN 即崩
6	全量重训 30 epoch	cls 显著跌破 0.765	0.27

过拟合实验 = 最小可复现实验：全量数据训不动时，先在 2 个样本上过拟合。2

个样本都过拟合不了的模型，100 个样本更不可能学好；反之若 2


个样本能过拟合而全量不行，差异就在数据多样性/正则化。先把链路在最小规模上打通，再扩大规模。

五、最终结果：9 张图逐图讲解


5.1 热图（4 张）：模型“看哪里”

热图是 cls 分支经 sigmoid 后的概率图，颜色越亮 = 模型认为该 BEV


网格存在该类物体的置信度越高。 “该亮的亮、该暗的暗” 是分类分支学对的第一标准。




Frame 0: car 通道亮斑 (-15,19)、(3,19) 对准两辆 car GT; ped 亮斑 (-11,-17); cyclist 通道全暗 (本帧无骑行者)



Frame 1: car (7,13)、ped (5,9)、cyclist (-14,-7), 三个类别三个位置互不串扰




Frame 2: car 通道全暗 (无 car GT), cyclist (6,3)、ped (-1,-11) 与 GT 一一对应。背景 X 形纹路是位置编码残差, 幅度 ≤ 0.1 不影响判读




Frame 3: ped (9,17)、(7,0) 与 cyclist (7,5), 全部对准 GT

5.2 检测图 (4 张) : 模型 “画什么”


黑色虚线 = GT, 红/绿/蓝实线 = 预测 (car / ped / cyclist) , 数字 = 置信度。




Frame 0: car 0.54、car 0.60、ped 0.44 三框全部套住 GT 虚线框，无重复框、无跨类别误报




Frame 1: car 0.5~0.7、ped 0.69、cyclist 0.52, 一框一物



Frame 2: ped 0.59 / 0.71、cyclist 0.45 / 0.46 对准 GT

Frame 3: ped 0.47×2 、cyclist 0.5×2 , 密集小目标全部分开

5.3 投影图 (1 张) : SCA 的“眼睛”



2500 个 BEV query 的 3D reference point 投影到各相机，呈放射状扇形铺开

每一条红色射线就是“某个 BEV 网格在某个相机里可能看到的位置”。SCA 做的事就是沿这些点采样图像特征并加权聚合回 BEV —— 投影图正常，是 SCA 能学到东西的几何前提。

5.4 最后一步：NMS 后处理

解码时每个物体周围的多个网格都会放电（各 0.1~0.6 分），直接画出来是一堆叠框。加入类别无关 NMS (IoU > 0.25 抑制) + 阈值 0.3 后，框数从 14/19/12/15 收敛到 4/4/5/4。NMS 是几乎所有检测器（含 BEVFormer 原版）的标准后处理，属于解码逻辑而非“改分数”。

六、知识点清单（今日新增）

#	知识点	一句话理解
1	Focal Loss 数值指纹	loss 卡在反常稳定值 = 模型输出的解析解，可反推任务可学性
2	数据-标签几何一致性	图像与 GT 必须源自同一份物体数据 + 同一套投影代码
3	meshgrid 展平顺序	x-major vs y-major 差一个转置，全链路必须统一
4	grid_sample 坐标系	[-1,1] 归一化的除数是原图尺寸，不是特征图尺寸
5	Self-Attention 归纳偏置	全连接 attention 会全局平均，deformable 保持局部性
6	Pre-LN vs Post-LN	小幅加性信号场景下 Post-LN 抹平信号，必须 Pre-LN
7	过拟合实验	2 样本 × 150 步是验证链路的最小可复现实验
8	组件消融	逐层加回组件，定位“哪一层引入病灶”
9	采样冷启动	offset 全零初始化 = 死锁，需散开初始化保证首步信息流
10	NMS	类别无关 NMS 去跨类重复框，是检测标准后处理

七、学习建议

7.1 这次调试暴露的短板与对策

短板	证据	对策
数值敏感度不足	cls=0.765 / reg=1.0 两个铁证摆了几天没被解读	每次训练先记 loss 初值与稳定值，学会算“理论最优解”
独立调试信心弱	中途两次想回退到“更早的坏版本”	建立“先实验后动手”清单：先跑探针，再改代码
坐标系直觉弱	meshgrid / grid_sample 两处坐标 bug	手推“物理坐标 → 像素坐标 → 归一化坐标”全链路并默写

7.2 下一步（1~2 周内）

- 默写链条：不看代码，手写“BEV query → SCA 采样 → head 解码”的 shape 变换链，写不出来说明还没真懂；
- 复现消融：把 Post-LN 消融实验自己从零搭一遍（裸 SCA / +LN / +FFN 三版），数值复现“加一层 LN 就崩”；
- 读原版对照：在 mmdet3d 0.x 分支 BEVFormer 源码中找出今天 6 个 bug 各自对应的“原版正确写法”，做对照笔记；
- 加分项：给 NMS 写一个旋转框（OBB）版本，为后续真数据做准备。

7.3 面试话术（可直接背）

“我做过一个 BEVFormer 简化实现的完整调试：模型不收敛，我从 loss 的稳定值反推出任务是‘不可学’的，然后用过拟合实验 + 组件消融逐层定位出 6 个嵌套 bug——数据几何不一致、meshgrid 展平顺序、grid_sample 归一化、TSA 全局平均、Post-LN 抹平加性信号、采样冷启动。最终 cls 从 0.765 降到 0.27，可视化亮斑与 GT 精确对齐。这段经历让我养成了‘先算理论值、再做最小实验、最后改代码’的调试习惯。”

这段话覆盖面试官最想听的三个维度：定位问题的方法论、对 transformer 细节的理解、可量化的结果。